

Contextualizando

Para a realização do TCC foi escolhido um dataset com dados do campeonato brasileiro de futebol de 2003 até 2024 encontrado no kaggle no seguinte link [Campeonato Brasileiro de futebol](#), este dataset tinha 4 repartições principais, sendo elas Estatísticas gerais da partida, os jogadores que tomaram cartão, os jogadores que fizeram gol e os dados da partida em geral. Para este trabalho apenas as tabelas de estatísticas e dos dados da partida serão utilizados.

A Tabela de estatísticas contém os seguintes atributos: ID, Rodada, Clube, Chutes, Chutes no alvo, posse de bola, passes, precisão no passe, faltas, cartão amarelo, cartão vermelho, impedimentos e escanteios, desta tabela não foi excluído nenhum atributo.

A tabela de dados gerais da partida contém os seguintes atributos: ID, Rodada, data, hora, mandante, visitante, formação mandante, formação visitante, técnico mandante, vencedor, arena, mandante placar, visitante placar, mandante estado, visitante estado, desta tabela ficaram apenas os atributos de ID, Rodada, Hora, Mandante, Visitante, Mandante placar, Visitante Placar e Vencedor.

Foram adicionados os atributos de ELO-Rating para cada equipe, sendo eles retirados do site [Elo - Campeonato Brasileiro](#).

Modificações

Após escolher os atributos que serão utilizados a tabela completa ficou da seguinte forma:

ID,rodada,data,hora,mandante,visitante,mandante_Placar,visitante_Placar,ELO_Rating_mandante,ELO_Rating_visitante,Chutes_mandante,Chutes_visitante,Chutes_no_alvo_mandante,Chutes_no_alvo_visitante,Posse_mandante,Posse_visitante,Passes_mandante,Passes_visitante,Precisão_passes_mandante,Precisão_passes_visitante,Faltas_mandante,Faltas_visitante,Cartão_amarelo_mandante,Cartão_amarelo_visitante,Cartão_vermelho_mandante,Cartão_vermelho_visitante,Impedimentos_mandante,Impedimentos_visitante,Escanteios_mandante,Escanteios_visitante,Vencedor. Os atributos da tabela de estatísticas foram divididos em mandante e visitante pois os dados estavam em tuplas separadas.

A seguir foi realizado uma redução nos dados do dataset por falta de informação ou informação incompleta, sendo assim o dataset passou de conter dados de 2003 até 2024 para 2015 até 2023:

O corte de 2003 até 2014 foi cortado por não conter informação das estatísticas da partidas;

partida_id	rodada	clube	chutes	chutes_no_alvo	posse_de_bola	passes	precisao_passes	faltas	cartao_amarelo	cartao_vermelho	impedimentos	escanteios
"1"	"1"	"Vasco"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"1"	"1"	"Guarani"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"2"	"1"	"Athletico-PR"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"2"	"1"	"Gremio"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"3"	"1"	"Flamengo"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"3"	"1"	"Coritiba"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"4"	"1"	"Goias"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"
"4"	"1"	"Paysandu"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"	"0"

Tuplas vazias no corte de 2003 até 2014

Os anos de 2015 e 2016 não continham os dados de chute ao gol de cada equipe, para arrumar isso foi adicionado na mão os dados utilizando o site da ESPN como provedor dos dados.

1	partida_id	rodada	clube	chutes	chutes_no_alvo	posse_de_bola	passes	precisao_passes	faltas	cartao_amarelo	cartao_vermelho	impedimentos	escanteios
9975	"4987"	"1"	"Chapecoense"	"13"	"0"	"45%"	"326"	"None"	"20"	"2"	"0"	"3"	"3"
9976	"4988"	"1"	"Atletico-MG"	"10"	"0"	"50%"	"426"	"None"	"14"	"4"	"0"	"4"	"2"
9977	"4988"	"1"	"Palmeiras"	"17"	"0"	"50%"	"406"	"None"	"20"	"2"	"0"	"2"	"11"
9978	"4989"	"1"	"Joinville"	"3"	"0"	"26%"	"250"	"None"	"14"	"0"	"1"	"1"	"3"

Tupla com o atributo chutes ao gol vazia

O ano de 2024 foi cortado por não conter nenhuma informação das estáticas das partidas;

1	partida_id	rodada	clube	chutes	chutes_no_alvo	posse_de_bola	passes	precisao_passes	faltas	cartao_amarelo	cartao_vermelho	impedimentos	escanteios
16812	"8486"	"1"	"Bahia"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16813	"8486"	"1"	"Internacional"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16814	"8487"	"1"	"Criciuma"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16815	"8487"	"1"	"Juventude"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16816	"8488"	"1"	"Fluminense"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16817	"8488"	"1"	"Bragantino"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16818	"8489"	"1"	"Sao Paulo"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"
16819	"8489"	"1"	"Fortaleza"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"

Tuplas vazias no de 2024

Em diversos anos do recorte que irá ser utilizado continuam alguns jogos que não continuam dados nenhum, por isso eles também foram cortados do dataset.

7008	"13"	"Bragantino"	"10"	"2"	"40%"	"377"	"80%"	"18"	"1"	"0"	"0"	"1"	"3"
7008	"13"	"Corinthians"	"12"	"4"	"66%"	"555"	"86%"	"13"	"2"	"0"	"0"	"1"	"8"
7015	"13"	"Vasco"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"	"0"
7015	"13"	"Atletico-MG"	"0"	"0"	"None"	"0"	"None"	"0"	"0"	"0"	"0"	"0"	"0"
7009	"13"	"Fluminense"	"8"	"5"	"48%"	"365"	"78%"	"21"	"1"	"0"	"0"	"2"	"4"
7009	"13"	"Botafogo-RJ"	"17"	"7"	"52%"	"385"	"80%"	"20"	"0"	"0"	"0"	"0"	"7"

Tuplas vazias ao decorrer do corte de 2015 até 2023

Generalização


Algumas das tuplas continham um ou dois atributos faltando para corrigir isso, esses atributos foram generalizados:

"5685"	"32"	"Santos"	"3"	"0"	"41%"	"368"	"None"	"16"	"3"	"0"	"0"	"4"	"1"
"5685"	"32"	"Chapecoense"	"20"	"0"	"59%"	"469"	"None"	"13"	"2"	"0"	"0"	"2"	"11"
"5686"	"32"	"Athletico-PR"	"4"	"0"	"58%"	"547"	"None"	"9"	"0"	"0"	"0"	"5"	"2"
"5686"	"32"	"America-MG"	"13"	"0"	"42%"	"398"	"None"	"8"	"0"	"0"	"0"	"1"	"5"
"5687"	"33"	"Ponte Preta"	"14"	"0"	"43%"	"330"	"None"	"23"	"3"	"0"	"0"	"0"	"1"
"5687"	"33"	"Sport"	"10"	"0"	"57%"	"428"	"None"	"12"	"2"	"0"	"0"	"2"	"3"

Tuplas vazias com mais de um atributo vazio

Quando foi adicionado os dados para chutes no alvo nos anos de 2015 e 2016 houve algumas partidas que não foi possível adicionar o valor para essa estatística por no site da ESPN não conter esses doado mas especificamente, no ano de 2015 alguns jogos do figueirense além de um jogo do cruzeiro, em 2016 alguns jogos do atlético-MG não continham nenhuma estática na ficha do jogo sendo assim não sendo possível adicionar esse valor, para que não

ficassem vazias esse valor, foi colocado no lugar o placar do jogo como sendo o número de chutes no alvo;



Site da ESPN sem estatísticas da partida

O atributo de precisão de passe em alguns jogos estava como NONE como na primeira imagem desta seção, para contornar isso foi adicionado no lugar a média geral da precisão de passe que é 80%;

O Atributo vencedor apenas mostrava o nome do time vencedor e quando não tinha vencedor aparecia o seguinte símbolo - que significa que houve um empate mas isso é algo nada intuitivo, para corrigir isso o - foi substituído por empate.